Database System 2020-2
Final Report

ITE2038-11800

2016024902

Seryung Yoon

Table of Contents

Overall Layered Architecture

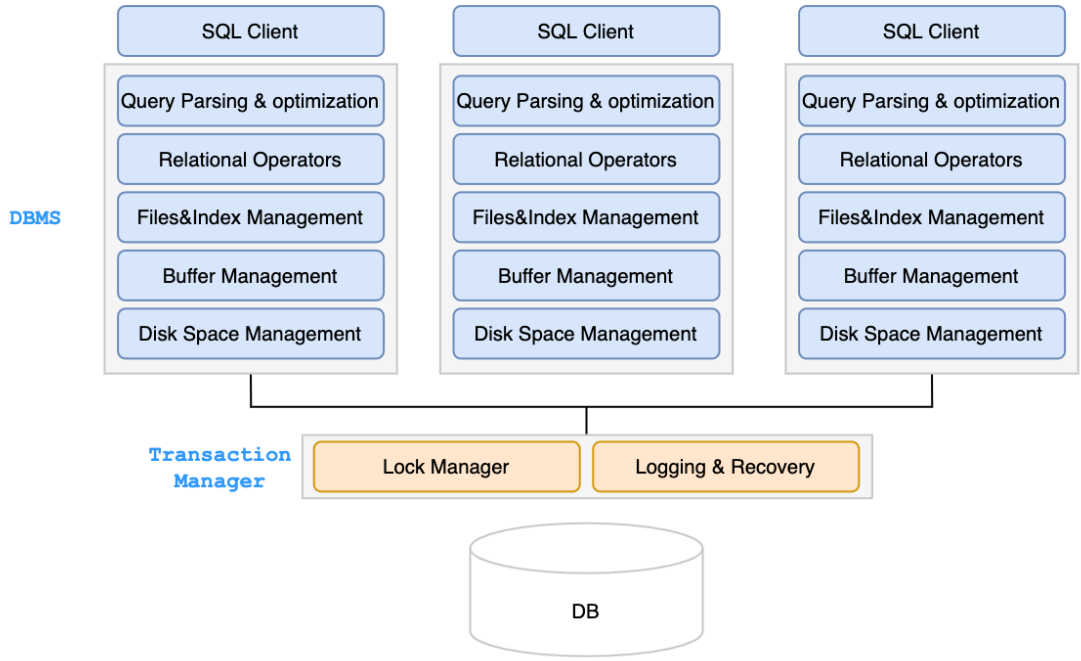

데이터베이스 관리 시스템(DBMS)이란 데이터를 효과적으로 이용할 수 있도록 보관하는 소프트웨어로, 사용자에게 파일 열기 및 데이터의 삽입과 삭제, 변경, 검색 API 를 제공한다. 사용자가 API Services 를 호출하면 on-Disk b+ tree 방식으로 작동하며, 페이지(4KB) 단위로 disk I/O 를 수행한다.

본 DBMS 에서 구현한 파트는 크게 6 부분으로 이루어진다. 각 계층에서는 자신이 맡은 기능만 수행하며, 다음 단계 레이어의 일을 호출하거나 넘길 때는 API 만 호출한다. 따라서 다른 계층에서 무슨 일을 하는지 알 필요가 없다.

1) Database API Layer

- **DB Initialize**
- **Open Table**
- **Insert (key, value)**
- **Find (key)**
- **Update (key, value)**
- **Delete (key)**
- **Close Table**
- **Shutdown DB**

사용자가 호출하는 API 에 대한 기능이 담겨있는 레이어로, 각 기능에 맞게 index layer 의 함수를 호출한다. DB 의 초기화 및 시작을 포함하여 파일 열기/닫기, 데이터 검색/삽입/변경/삭제, DB 종료 함수를 제공한다.

2) Files & Index Management Layer

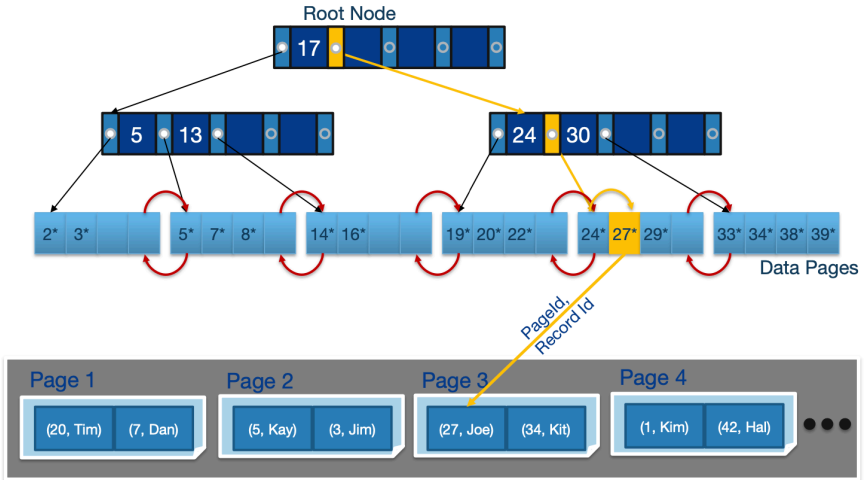

보다 효율적인 구조를 위해 b+ tree Index 방식을 차용하여 insert 와 delete 를 효율적으로 수행한다. B+ tree 란 key 에 의해 식별되는 레코드의 효율적인 삽입, 검색, 삭제를 통해 정렬된 데이터를 표현하기 위한 트리 자료구조이다. b+ tree 는 data entry 를 leaf 에 저장하고, root 와 internal page 에는 어디에 특정 rid 가 저장되어 있는지를 알려주는 key 가 저장되어 있어 routing 역할을 한다. 또한 leaf page 는 linked list 형태로 서로 연결되어 있으며, 오름차순으로 정렬되어 있어 순차적인 탐색에 매우 유리하다.

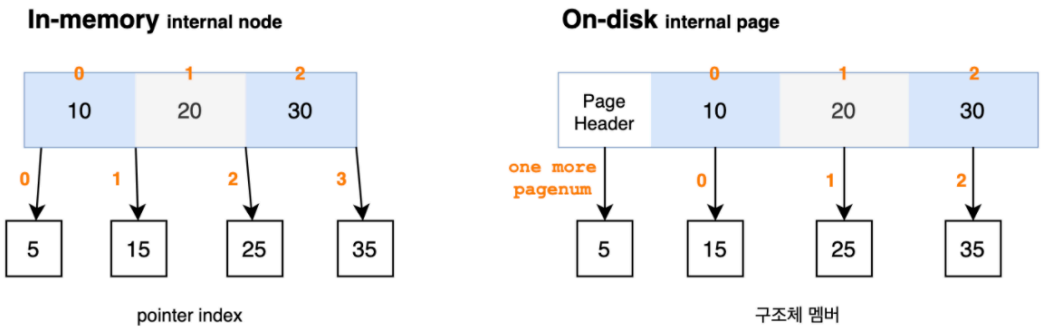

기존 in-memory b+ tree 는 node 구조체를 선언하여 child node 를 가리키는 데 pointer 를 이용한 반면, 본 프로젝트에서 구현한 on-disk b+ tree 는 page 구조체 안의 pagenum 멤버를 통해 child page 에 접근하는 차이가 있다. 특히, 각 트리에서 leftmost page 를 가리키는 방식에 가장 큰 차이가 있다. Pointer 에서는 0 번째가 가리키던 node 가 leftmost node 였지만, 본 프로젝트에서는 internal page 의 가장 앞에 위치한 128byte 짜리 Page header 내부에 속한 li_pagenum(one more pagenum) 멤버가 leftmost page 의 page number 이다.

B+ tree 에서 트리의 구조가 변경이 일어나는 경우는 merge 와 split 이 있다. 그 중 데이터를 삭제하면서 발생하는 redistribute 는 split 될 확률을 서로 비슷하게 만들어준다는 장점이 있지만, page 의 내용이 변경되므로 disk 상의 page 를 두 번 써야 할 일이 발생할 가능성이 있어 이 점을 고려해서 사용해야 한다. 본

프로젝트에서는 tree structure modification 을 줄이기 위해 페이지 내의 key 가 하나도 없을 경우에만 merge 를 수행하도록 구현하였다. 그러나 leaf page 에서 key 가 하나도 없어 coalesce(delayed merge)가 발생하는 경우에 속하면서 neighbor page 가 가득 차 있는 상태였다면, 이후 이 이웃 페이지에 insert operation 이 한 번이라도 들어오게 되면 결과적으로 merge-split 이 발생하여 2 번의 트리 구조 변경이 발생하게 된다. 이런 경우에는 structure modification 을 줄이기 위해 redistribution 이 필요하다고 판단하였다.

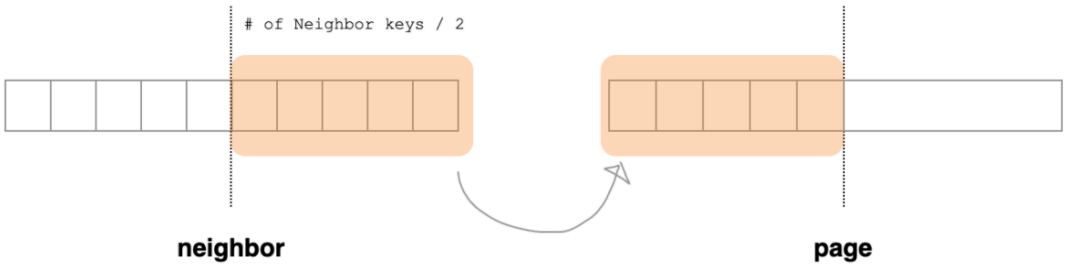

따라서 internal page 에서 key 가 존재하지 않아 delayed merge 를 해야 하는 경우에 속하면서, capacity 를 만족하지 못하여 merge 를 수행하지 못하는 상황에서만 예외적으로 redistribute 를 수행하도록 구현하였다. 기존의 redistribution 은 이웃 페이지의 key 를 한 개만 가져오지만, 이후 이 페이지에 delete operation 이 들어와 또다시 structure modification 이 일어나는 경우를 방지하기 위해 (neighbor page 의 key 개수/2)개씩 가져오도록 하여 성능을 향상시켰다.

3) Buffer Management Layer

DB 의 콘텐츠는 디스크에 저장되어 있고, 디스크의 속도는 메모리에 비해 매우 느리다. B+ tree index 를 이용해 disk I/O 가 $\log_F B$로 줄었으나 index layer 와 disk layer 의 속도 차는 여전히 존재한다. Buffer Management Layer 는 이 속도차를 완충시키고 DBMS 의 효율성을 높여 성능을 결정하는 데 중요한 역할을 하는 부분이다.

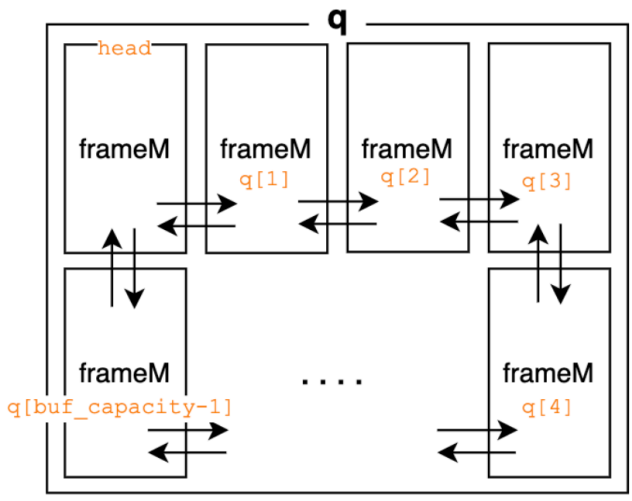

buf_capacity = num_buf (버퍼 풀 안의 총 프레임 수)
num_frames (현재 들어있는 프레임 수)

Frame manager 구조체 frameM 안에는 header page, general page 를 담고 있는 union 형 구조체 page_t 와 해당 페이지의 meta data 를 담고 있다. DBMS 를 초기화할 때 인자로 받은 num_buf 의 수만큼 프레임이 생성되며, 각 프레임은 이전/다음 프레임의 인덱스를 나타내는 int 형 변수 prev/next 를 담고 있어 circular queue 처럼 동작한다.

Table list 는 (최대 테이블 개수+1)개만큼의 구조체 배열로, 총 10 개의 hash table 을 사용한다. Table id 는 1 부터 시작하므로 연산의 편의성을 위해 table list[1]부터 사용하기 위해 max_table 의 값으로 11 을 정의하였다. 해당 페이지가 버퍼에 올라와 있는지의 여부를 확인하는 hash table 은 C++ STL library 중 map 을 활용하였다.

기존 index layer 에서 호출하던 disk space layer 함수 file_read/write_page() 의 역할과 같이 buffer 내의 페이지를 읽고 쓰기 위해 buf_read/write_page() 함수를 선언하였다. 버퍼 레이어에서는 테이블이 닫히거나 flush 가 발생할 경우에만 file write 가 실행되어야 하므로, buf_write_page()에서도 file_read_page()를 호출한다. buffer 가 비어 있을 경우에만 file_write_page()를 호출하여 disk I/O 를 줄였다. 또한, 버퍼와 페이지의 값을 수정하자마자 바로 buffer_latch, page_latch 를 해제함으로써 다른 트랜잭션이 delay 없이 바로 해당 버퍼/페이지에 접근할 수 있도록 구현했다.

b+ tree 구조와 buffer/page/record latch 에 따라 특정 레코드에 접근하는 순서는 다음과 같다.

1	global buffer latch 획득
2	B+ tree 의 root page 에 속하는 버퍼 풀 페이지 탐색 (버퍼에 없다면, 디스크로부터 읽어오기)
3	buffer latch 해제
4	2 와 3 을 반복하여 찾고자 하는 레코드가 담긴 leaf page 까지 탐색 + page latch 획득
5	Lock manager latch 획득 + record lock 획득 시도
6-1	레코드 lock acquire 에 성공한 경우: lock manager latch 해제
6-2	레코드 lock acquire 에 실패한 경우: transaction manager latch 획득
	Transaction latch 획득 + transaction manager latch 해제
	Transaction latch 를 제외한 나머지 latch 모두 해제하기(page latch, lock manager latch 등)
	해당 transaction latch sleep 시키기 => 앞의 락이 해제되면서 깨워줌(자동으로 transaction latch 는 해제됨)
7	page latch & record lock 획득

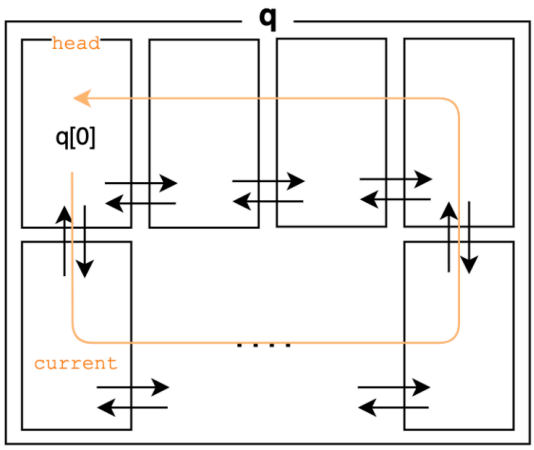

버퍼 풀이 가득 차 있는 경우, LRU Policy 에 의거하여 page eviction 이 발생하도록 구현하였다. LRU(Least Recently Used)는 가장 오랫동안 사용하지 않은 데이터는 앞으로도 사용할 확률이 적다는 이론 하에 가장 오랫동안 참조되지 않은 데이터를 제거하는 알고리즘이다. Buffer 는 `prev/next` 로 연결된 double linked list 구조이므로 새로운 프레임이 추가되는 위치는 항상 `head` 가 가리키는 부분이다. 따라서, 가장 오래 된 프레임은 `head` 프레임의 `prev` 프레임이 된다.

여러 트랜잭션이 버퍼에 동시에 접근하는 경우, 한 트랜잭션이 특정 페이지의 내용을 읽거나 쓰는 사이 다른 트랜잭션에서 해당 페이지가 evict 될 위험이 있다. 따라서 버퍼 전체를 보호하는 `buffer_latch` 와, DBMS 의 효율성을 높이기 위해 `page_latch` 를 선언하여 페이지의 순차적 접근을 보장하였다. `page_latch` 를 획득하면 해당 페이지는 사용 중임을 나타내므로 eviction 대상에서 제외된다.

4) Disk Space Management Layer

`Index layer` 에서 알려 준 `record` 의 위치를 통해 실제 disk 에 I/O 를 담당하는 부분으로, page(4KB) 단위의 I/O 를 진행하기 위해 페이지 생성 및 해제와 read/write system call 을 호출해주는 역할을 한다. `Index layer` 와 `buffer layer` 에서 해당 페이지를 저장하기 위한 read/write page API 를 호출하면, `disk space management layer` 에서 page 기반 주소를 physical 주소(해당 파일 넘버, offset)으로 변경해서 최종 read/write system call 을 호출한다.

파일은 paginated layout 으로, `disk space layer` 가 각 파일의 균등화된 offset(4KB)마다 해당 페이지 번호를 맵핑한다. 파일의 가장 앞에는 해당 파일의 metadata 가 담긴 `header page` 가 존재하여 레코드의 개수, free space 의 위치 등을 저장한다. Free space 가 모두 소진되는 순간 새로 여러 장의 페이지를 생성하는 방식으로 구현하였다.

5) Lock Manager & Transaction Manager

DBMS 의 병행제어(concurrency control)을 담당하고 있는 부분으로, 많은 사용자의 요청을 받아 빠른 시간 내에 올바른 결과를 도출하도록 구현하였다. 데이터베이스는 다수의 사용자들이 한 레코드에 동시에 접근하는 경우가 빈번하게 발생하는데, 이런 상황에서 적절한 처리가 이루어지지 않는다면 데이터베이스의 무결성이 깨져

트랜잭션의 수행에 대해 비정상적인 결과가 나올 수 있다. 따라서 본 DBMS 에서는 transaction manager 에서 제공하는 Concurrency Control 을 통해 DB 를 consistent 한 상태로 유지하여 사용자로 하여금 혼자서만 데이터베이스를 사용하는 것처럼 느낄 수 있게 하였다. Concurrency control 에 대해서는 아래에 자세히 기술하였다.

6) Logging & Recovery Layer

장애가 발생했을 때 안전하게 DB 의 상태를 올바르게 복구하는 crash recovery 와 관련된 API 를 담은 레이어이다. Crash recovery 에 대해서는 아래에 자세히 기술하였다.

Concurrency Control Implementation

트랜잭션이란 하나의 논리적 작업 단위를 구성하는 일련의 연산들의 집합으로, 프로그램 수행의 단위이다. 트랜잭션의 대표적인 예로 계좌 이체가 있다. 계좌 A 에서 계좌 B 로 5 만원을 송금하는 이체 작업은 전체 작업이 정상적으로 완료되거나, 정상적으로 처리될 수 없는 경우에는 아무것도 실행되지 않은 처음의 상태로 돌아가야 한다.

트랜잭션은 문제 없이 정상적으로 수행되어 `commit` 으로 종료되거나, 사용자의 요청에 의해 `abort` 되거나 시스템이 문제를 감지하여 DBMS 가 이를 `abort` 하는 경우가 있다. DBMS 는 이와 같은 상황에서 트랜잭션을 적절하게 관리하여 사용자로 하여금 정상적인 데이터에 접근할 수 있도록 해 주어야 한다.

트랜잭션이 동시에 실행되는 환경에서 발생 가능한 문제로는 크게 아래의 세 가지가 있다.

1) The Lost Update Problem

P1	Time	P2
	/* x = 100 */	
r (x)	1	
	2	r (x)
x := x+100	4	x := x+200
w (x)	5	
	/* x = 200 */	
	6	w (x)
	/* x = 300 */	

update “lost”

Observation: problem is the interleaving $r_1(x)$ $r_2(x)$ $w_1(x)$ $w_2(x)$

서로 다른 트랜잭션이 한 레코드에 `write` 를 연속으로 수행하는 경우, 먼저 실행된 트랜잭션 P1 은 정상적으로 실행되었으나 P2 에 의해 overwrite 되어 x 의 값이 변경되지 않는 문제가 발생한다.

2) Inconsistent Read Problem

P1	Time	P2
	1	r (x)
	2	x := x – 10
	3	w (x)
sum := 0	4	
r (x)	5	
r (y)	6	
sum := sum +x	7	
sum := sum + y	8	
	9	r (y)
	10	y := y + 10
	11	w (y)

“sees” wrong sum

Observations:

problem is the interleaving $r_2(x)$ $w_2(x)$ $r_1(x)$ $r_1(y)$ $r_2(y)$ $w_2(y)$

no problem with sequential execution

rw-confilct 의 경우, 위의 상황에서는 x+y 의 값이 일정하지 않게 되면서 문제가 발생하게 된다.

3) Dirty Read Problem

P1	Time	P2
r (x)	1	
x := x + 100	2	
w (x)	3	
	4	r (x)
	5	x := x - 100
failure & rollback	6	
	7	w (x)

cannot rely on validity
of previously read data

Observation: transaction rollbacks could affect concurrent transactions

위의 예시도 rw-conflict 의 상황 중 하나로, 한 트랜잭션(P1)이 중간에 `abort` 되는 경우 동시에 같은 레코드에 접근 중이던 다른 트랜잭션(P2)은 dirty 한 값을 가져와서 `write` 를 수행하게 된다.

Serializable 이란 어떤 트랜잭션들이 중첩되어 실행되는 것과 순차적으로 실행되었을 때의 결과가 같을 때를 일컫는 것으로, 2PL(Two Phase Locking) Protocol 에 의해 보장된다. 2PL 은 위와 같은 문제를 해결하기 위해 상호 배제 기능을 제공하는 기법이다. 2PL 을 따르는 트랜잭션은 반드시 reading 전에 `S-lock` 을, writing 전에 `X-lock` 을 획득하여야만 해당 operation 을 수행할 수 있다. 또한, 획득한 락을 해제하기 전까지는 다른 어떤 락도 추가로 얻을 수 없다.

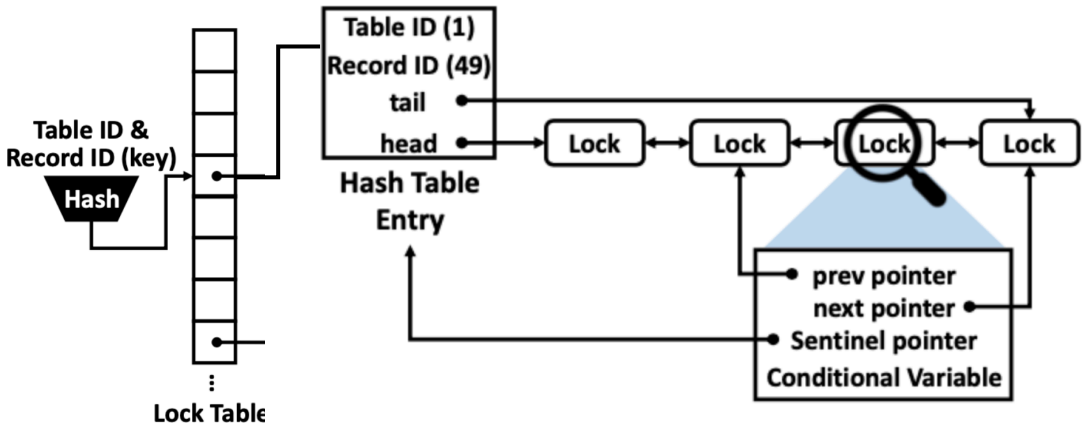

각 튜플(레코드)별로 락의 요청과 획득을 나타내기 위해 선택한 디자인은 다음과 같다. C++ STL Library 인 `map` 을 활용하여 `(table id, record id)`가 `key` 이고 `value` 로는 hash entry 형 구조체를 갖는 `lock table` 을 두고, 해당 hash entry 의 `head` 와 `tail`, 각 lock 구조체가 가진 `prev, next` 포인터를 통해 한 레코드에 동시에 접근하는 락의 waiting list 를 표현하였다. Double linked list 로 구현된 `Lock list` 는 획득 및 해제 요청을 하는 락 오브젝트의 전/후로 충돌 가능성이 있는 다른 락 오브젝트가 존재하는지를 판단한다.

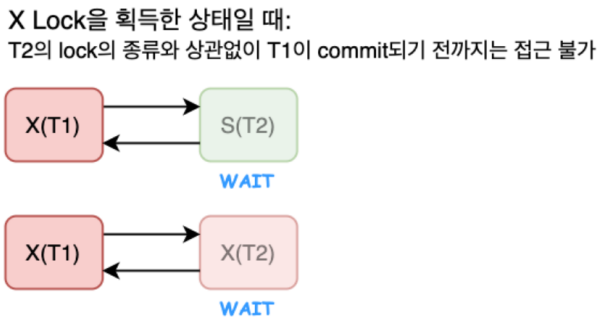

Lock mode 는 크게 Shared Lock(S)과 Exclusive Lock(X)으로 나뉜다. 값의 읽기만 가능한 S-lock 과 달리 X-lock 은 레코드 값을 읽고 쓰는 것이 가능하도록 해 주는 락이다. 따라서 어떤 트랜잭션이 X-lock 을 획득한 상태라면, 이 트랜잭션이 commit 되기 전까지 다른 트랜잭션은 해당 레코드에 접근할 수 없다.

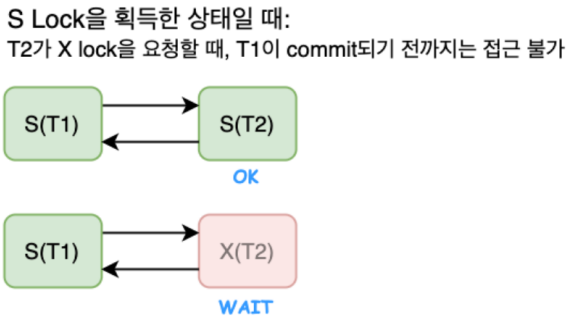

반면 S-lock 을 획득한 상태라면, 다른 트랜잭션의 읽기 접근(S-lock 획득)은 허용된다. 동시에 다수의 트랜잭션이 한 레코드의 값을 읽기만 하는 것은 conflict 가 발생하지 않기 때문이다. 그러나 다른 트랜잭션이 X-lock 을 요청한다면, 해당 요청은 기존의 돌아가고 있는 트랜잭션이 commit 될 때까지 기다리게 된다. 기존 트랜잭션에서 여러 번 db_find()를 호출한다고 할 때, 동시에 다른 트랜잭션에서 db_update()로 값 변경을 해버리면 db_find()의 결과가 다르게 나올 수 있기 때문이다.

따라서 본 프로젝트에서는 아래와 같이 lock_acquire 가 실행되도록 구현하였다. 기존 트랜잭션의 lock mode 가 새로 요청받는 트랜잭션의 lock mode 보다 더 강력하거나 같을 경우, 트랜잭션의 동일함 여부와 상관없이 lock list 와 transaction list 에 새로 lock 을 추가할 필요 없이 기존의 락 오브젝트를 반환한다. 어차피 '락'은 어떤 트랜잭션이 해당 레코드의 락을 획득하였는지(=현재 시점에 값에 접근할 수 있는지) 알기 위한 개념이므로, 더 강력한 락이 존재한다면 새로 acquire 할 필요가 없다고 판단하여 위와 같이 구현하였다.

기존 트랜잭션의 lock mode 보다 새로 요청받는 트랜잭션의 lock mode 가 더 강력한 경우에는 트랜잭션의 동일함 여부에 따라 case 를 나누어 구현하였다. 같은 트랜잭션에서 더 강력한 lock mode 를 요청하는 경우, lock 을 한 단계 업그레이드 시켜주기 위해 new lock 을 반환한다. 이 때, lock list 와 transaction list 에 new lock 을 추가하고, 기존의 S-lock 은 conversion deadlock 을 위해 제거하지 않고 둔다. 두 트랜잭션이 다른 경우, 앞의 트랜잭션이 trx_commit()을 호출하면서 lock 을 release 할 때까지 lock 의 cond 변수를 이용하여

기다리게 함으로써 기존 트랜잭션이 종료되어야만 뒤의 X-lock 을 획득하면서 새로운 트랜잭션이 마저 실행될 수 있도록 구현하였다.

i) lock's mode >= new_lock's mode인 경우

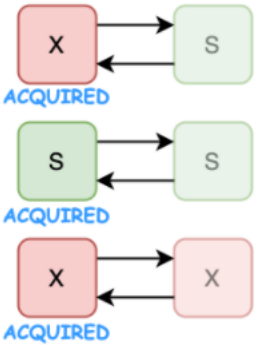

- lock list, trx list에 new lock을 달 필요 X
- return: 기존의 lock

ii) lock's mode < new_lock's mode인 경우 (같은 트랜잭션)

- lock list, trx list에 추가
- return: new lock

iii) lock's mode < new_lock's mode인 경우 (다른 트랜잭션)

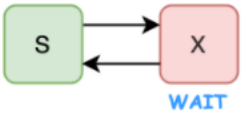

- lock list, trx list에 추가
- 앞의 트랜잭션이 commit될 때까지 wait
- 앞의 트랜잭션이 모두 종료되면 X lock 획득
- return: new lock

Deadlock 이란 두 개 이상의 트랜잭션이 서로 lock 이 해제되기를 기다리면서 DBMS 가 무한 대기 상태에 빠지는 현상이다. 본 DBMS 에서는 deadlock 을 해결하기 위해 deadlock detection method 를 차용하였다. 두 개 이상의 트랜잭션이 서로를 기다리는 cycle 현상이 탐지되면 deadlock 이 발생했다고 판단하고 현재까지 진행한 트랜잭션을 abort 하는 작업이 필요하다. 서로를 기다리고 있는지를 확인하기 위해 다음과 같은 디자인으로 구현하였다.

```
int trx_isDeadlock(int trx_id, lock_t *lock) {

    pthread_mutex_lock(&trx_manager_latch);
    // deadlock is detected when trx is waiting itself.
    // so check trx's wait lock list to detect deadlock.
    if (lock->prev == NULL) {
        pthread_mutex_unlock(&trx_manager_latch);
        return false;
    }
    int tmp_trx_id = lock->prev->owner_trx_id;
    lock_t *tmp = trx_manager[tmp_trx_id]->lock_list;
    while (tmp->trx_next_lock != NULL) {
        if (tmp->owner_trx_id == trx_id)
            return true;
        tmp = tmp->trx_next_lock;
    }
    pthread_mutex_unlock(&trx_manager_latch);
    return false;
}
```

우선 `lock_acquire()`에서 새로 획득한 lock 을 lock list 에 추가하고 나서, 자신보다 선행된 락 오브젝트의 `owner_trx_id` 속성을 이용하여 선행 락을 가지고 있는 주인 트랜잭션을 찾는다. 트랜잭션 id 를 안다면 트랜잭션 테이블 map 을 통해 해당 트랜잭션의 lock list 를 순회할 수 있다. 만약 `trx_id` 가 일치하는 락이 존재한다면 deadlock 상태에 교착된다는 뜻이므로, `true` 를 반환한다. Lock list 를 순회하여도 일치하는 락이 없는 경우, `false` 를 반환하여 해당 락 오브젝트는 데드락을 발생시키지 않음을 증명한다.

Crash-Recovery Implementation

DBMS 에서는 SQL 을 실행하는 동안 트랜잭션 장애, 시스템 장애, 미디어 장애 등으로 인한 비정상적인 종료가 발생할 수 있다. DBMS 의 Atomicity 와 Durability 를 보장하기 위해서는 트랜잭션을 수행하는 도중 장애로 인해 손상된 DB 를 손상되기 이전의 정상 상태로 복구시키는 작업이 필요하다.

Undo 란 로그를 이용하여 오류가 발생한 트랜잭션과 관련된 모든 변경을 취소하여 복구를 수행하는 방법이고, Redo 란 로그를 이용하여 오류가 발생한 트랜잭션을 재실행하여 복구를 수행하는 방법이다. 따라서 Undo 와 Redo 를 수행하기 위해 트랜잭션이 반영한 DB 의 변경사항을 별도의 로그 파일에 따로 기록해둔다. 로그(log)란 로그 레코드의 모임으로, 각 로그 레코드는 LSN(Log Sequence Number)이라는 고유 식별자를 가진다. 로그는 항상 뒤에 추가되는 방식으로 기록되므로 LSN 은 단조 증가한다.

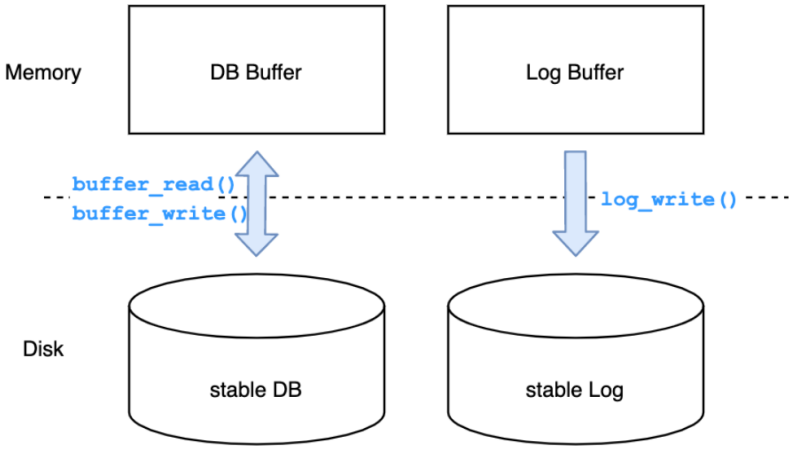

DB 에 buffer 의 내용을 write 하기 전에 logging 작업을 우선 실행하는 것을 WAL(Write-Ahead Logging)이라고 하는데, 후에 DBMS 에 장애가 발생하더라도 로그 파일을 이용해서 DB 를 정상적인 상태로 복구시킬 수 있게 해 준다. DB buffer 와 마찬가지로 성능을 위해 로그 버퍼에 로그 레코드를 일정 수만큼 모아뒀다가 로그 파일에 write 를 진행하도록 구현하였다. 따라서 로그 레코드가 버퍼에서 파일에 써질 때는 다음 상황 중 하나가 될 것이다.

1) 어떤 트랜잭션이 commit을 요청한 경우
2) WAL을 해야 하는 경우
3) 로그 버퍼가 꽉 찬 경우(본 프로젝트에서는 로그 버퍼의 크기를 10MB로 설정하였다.)

로그 레코드는 Redo 와 Undo 에 관련된 정보를 포함하고 있다. 따라서 로그는 Redo 정보만을 담은 레코드와 Undo 정보만을 담은 레코드, 그리고 둘을 모두 담고 있는 Undo-redo 레코드가 있다. Redo 레코드는 트랜잭션이 실패한 경우 트랜잭션에서 변경한 내용을 재실행하기 위한 정보가 들어있다. Undo 레코드는 트랜잭션이 rollback 할 때 변경했던 내용을 되돌리는 데 필요한 정보가 들어있다. 본 DBMS 에서는 로그 레코드 구조체 안의 old image 와 new image 멤버를 이용하여 데이터의 변경 전, 변경 후 이미지를 복제하여 저장하는 방식으로 구현하였다.

본 DBMS 에서는 ARIES method 를 기반으로 recovery 를 수행하도록 구현하였으나 checkpoint 에 대해서는 고려하지 않았으며, torn pages 가 발생하는 경우 또한 고려하지 않고 구현하였다. ARIES method 는 C.Mohan 이 발명한 데이터베이스 복구 알고리즘으로, 수많은 상용 DBMS 에서 사용 중인 방법이다. WAL 과 LSN 을 기반으로 No-force/Steal 정책을 따르며 효율적으로 복구를 수행한다.

ARIES metod 는 크게 세 단계로 구성되어 있다.

1) Analysis Pass

트랜잭션의 리커버리 시 가장 먼저 실행되는 부분으로, Redo-winners 패러다임의 analysis 알고리즘을 통해 winner 와 loser 트랜잭션을 찾는다. stable log 의 처음부터 끝까지 scan 하며 트랜잭션의 commit 로그가 존재하지 않는다면, Undo 의 대상이므로 loser 트랜잭션 리스트에 추가한다. 어디서부터 시스템이 복구를 시작해야 하는지, 어느 트랜잭션들을 복구해야하는지를 알아낸다.

2) Redo Pass

시스템 장애 시에 데이터베이스를 해당 상태로 복원하는 부분이다. Stable log 에 저장된 내용을 이용해 순서대로 다시 실행하여 DB 를 원래 상태로 복구한다.

버퍼 풀 내부 페이지의 header 에 기록된 page LSN < 로그 레코드의 LSN 일 경우에만 반복해서 Redo 를 진행하는데, 이는 WAL 에 의해 순차적으로 기록되고 LSN 의 sequence 가 증가하기 때문에 page LSN 이 로그 레코드의 LSN 보다 크거나 같다는 것은 현재 stable DB 가 이미 최신 상태라는 것을 의미하기 때문이다. Redo 를 진행하고 나면 해당 페이지의 pageLSN 을 갱신한다.

3) Undo Pass

트랜잭션의 deadlock 상태가 감지되어 trx_abort()를 호출하면 기존의 값을 저장해 둔 undo_log 에서 값 변경이 일어난 레코드 부분을 다시 되돌리는 작업이 일어난다. 모든 Loser transaction 의 write operations 를 Stable Log 에 저장된 역순으로 rollback 한다. Analysis Pass 에서 판별된 Loser 트랜잭션은 uncommitted 상태에서 crash 가 발생했다는 의미이므로, DBMS 의 Atomicity(All or Nothing)를 보장하기 위해 트랜잭션의 실행 전 상태로 DB 를 돌려놓도록 구현한다.

operation 수행 중 수정된 페이지들이 버퍼 관리자의 page eviction 에 따라 디스크에 출력될 수 있는데, 이 때 아직 완료되지 않은 트랜잭션이 수정한 페이지가 디스크에 출력될 가능성이 있다. 트랜잭션이 정상적으로 종료되지 않았다면 트랜잭션이 변경했던 모든 페이지를 다시 원상복구시켜야 한다.

따라서 Stable log 가 기록된 역순으로 new image->old image 의 대체과정을 해당 트랜잭션의 시작 로그까지 반복하면 Undo 가 완료된다.

Undo 를 수행하고 나면 해당 Undo 작업에 대한 보상 레코드 CLR 이 발급되는데, 이는 'Undo 로그의 이전 로그'를 가리키게 해서 한 번 Undo 된 로그를 다시 접근해서 re-undo 되는(원상복귀) 현상을 방지한다.

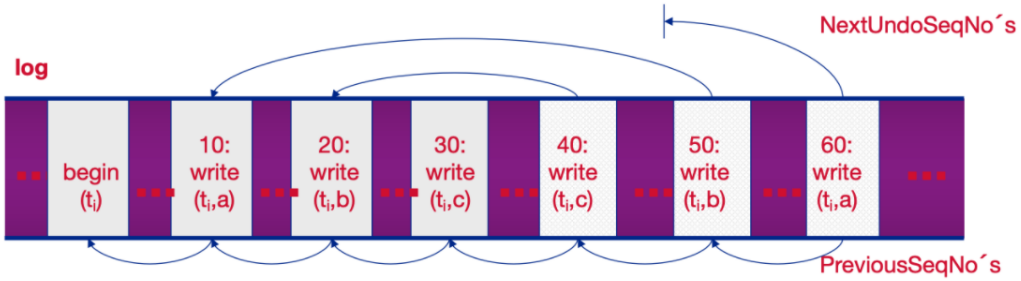

또한 compensate log record 에만 존재하는 next_undo_LSN 을 통해 해당 트랜잭션의 다음 Undo action 을 기록해두고, 이미 Undo 를 수행한 상태일 경우 이 부분을 통해 part skip 이 가능하게 구현한다. 이를 통해 undo recovery 를 진행하면 할수록 트랜잭션의 시작 지점에 가깝게 undo sequence number 가 설정되고, 결과적으로 undo recovery 가 도중에 계속 failure 가 나더라도 수행해야 할 Undo 의 양은 줄어들게 되어 성능을 향상시킬 수 있다.

In-depth Analysis

1. Workload with many concurrent non-conflicting read-only transactions.

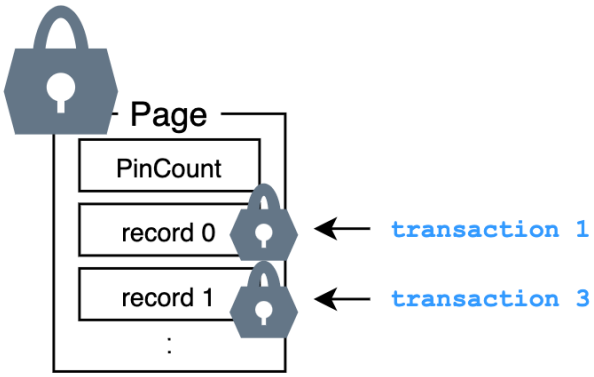

페이지 구조체에 int 형 변수 `pinCount` 를 추가하여 `mutex` 와 `pinCount` 를 함께 사용한다. `pinCount` 가 0 이 아니면 다른 트랜잭션이 해당 페이지를 사용 중이라는 의미이나, 만약 락 획득을 요청한 락의 종류가 `S lock` 이라면 `page latch` 와 상관 없이 바로 레코드 락을 획득하도록 구현한다. 결과적으로 한 페이지 내에 다른 레코드들에 접근하는 트랜잭션끼리의 병목현상이 일어나지 않게 되고, many concurrent non-conflicting read only transactions 상황에서의 성능 향상을 기대해볼 수 있다.

2. Workload with many concurrent non-conflicting write-only transactions.

서버를 여러 개 증축하는 distributed database architecture 를 통해 `cache` 를 여러 개 두고, 사용자마다 특정 ip(entry point)로 서버에 접속하여 `write operation` 을 수행하도록 한다면 DBMS 의 성능과 신뢰성 모두 높일 수 있다. 또는 host RAM 의 크기를 늘려서 CPU 의 보틀넥을 해결하는 방법이 있을 것이다.